

文档结构化处理 Pipeline

这是一个文档预处理 Pipeline，整合 MinerU 文档解析、Kimi 文档整理、图片处理和归档四个阶段，将 PDF/Word/PPT/图片等文档自动转换为结构化 Markdown 文档。

快速开始

1. 配置环境变量

复制 `.env.example` 为 `.env`，并填写你的 API Token：

```
cp .env.example .env
# 编辑 .env 文件，填入你的 API Token
```

`.env` 文件内容：

```
# MinerU API 配置
MINERU_BASE_URL=https://mineru.net/api/v4
MINERU_API_TOKEN=your_mineru_token_here

# Kimi API 配置
KIMI_API_KEY=sk-your_kimi_api_key_here
KIMI_MODEL=kimi-k2.5
KIMI_BASE_URL=https://api.moonshot.cn/v1
```

2. 准备输入文件

将待处理的文档放入 `./input/` 目录：

```
mkdir -p input
cp your-document.pdf input/
```

支持的文件格式：

- PDF (`.pdf`)
- Word (`.doc`, `.docx`)
- PowerPoint (`.ppt`, `.pptx`)
- 图片 (`.png`, `.jpg`, `.jpeg`, `.webp`, `.gif`, `.bmp`)
- HTML (`.html`, `.htm`)

3. 运行 Pipeline

```
python pipeline.py
```

Pipeline 会依次执行四个阶段：

- 1. **Stage 1:** MinerU 文档解析 - 将输入文件解析为 Markdown
- 2. **Stage 2:** Kimi 文档整理 - 按照模板格式重新整理内容
- 3. **Stage 3:** 图片处理和链接更新 - 移动图片并更新链接
- 4. **Stage 4:** 归档中间文件 - 将中间文件归档到时间戳目录

4. 查看结果

最终结果保存在 `./output/` 目录：

```
ls output/
```

目录结构

.

├── input/

├── mineru_output/

├── kimi_output/

├── output/

├── data/

│ ├── {timestamp}/

│ │ ├── input/

│ │ ├── mineru_output/

│ │ └── kimi_output/

├── stages/

│ ├── __init__.py

│ ├── base_stage.py

│ ├── mineru_stage.py

│ ├── kimi_stage.py

│ ├── image_stage.py

│ └── archive_stage.py

├── config.py

├── pipeline.py

├── CLAUDE.md

├── README.md

└── .env

输入文件目录

阶段1: MinerU 解析输出

阶段2: Kimi 处理输出

阶段3: 最终输出

阶段4: 归档目录

Pipeline 阶段模块

Stage 基类

阶段1: MinerU 文档解析

阶段2: Kimi 文档处理

阶段3: 图片处理

阶段4: 归档

统一配置模块


Pipeline 主程序

项目文档

用户文档

环境变量配置（用户创建）

执行流程



```
- 调用 MinerU API 解析 PDF/Word/PPT/图片
- 输出 Markdown + 图片到 ./mineru_output/
↓
[阶段2: Kimi 文档处理]
- 调用 Kimi API 按模板重新整理内容
- 输出处理后的 Markdown 到 ./kimi_output/
↓
[阶段3: 图片处理和链接更新]
- 移动图片到目标目录
- 处理 Markdown 内容（添加标题、分隔符）
- 更新图片链接
- 输出最终结果到 ./output/
↓
[阶段4: 归档中间文件]
- 归档 input/, kimi_output/, mineru_output/ 到 data/{timestamp}/
- 重新创建空的源目录
```

配置说明

MinerU 配置

在 `config.py` 中可以修改 MinerU 的配置：

```
# MinerU 处理配置
MINERU_MODEL_VERSION = "v1m" # 可选: "pipeline", "v1m", "MinerU-HTML"
MINERU_ENABLE_TABLE = True # 是否开启表格识别
MINERU_ENABLE_FORMULA = False # 是否开启公式识别
MINERU_LANGUAGE = "ch" # 文档语言
```

图片处理配置

```
# 图片处理配置
IMAGE_BASE_URL = "http://172.16.75.37:60128/pic" # 图片服务器基础URL
IMAGE_TARGET_DIR = Path("D:/工作/信息数据系/文件服务器/pic") # 图片目标目录
```

故障排查

常见问题

1. 导入错误

```
# 确保在虚拟环境中安装了依赖
pip install -r requirements.txt
```

2. API Token 错误

- 检查 `.env` 文件是否存在
- 确认 API Token 是否正确

3. 目录权限错误

- 确保程序有权限读写输入输出目录

调试模式

可以单独运行某个 stage 进行调试：

```
# 测试 MinerU Stage
from stages.mineru_stage import MinerUStage

stage = MinerUStage()
result = stage.run(
    input_dir=Path("./input"),
    output_dir=Path("./test_output")
)
print(result)
```